Лекция 3

Теория вероятностей (продолжение). Ковариация и корреляция

Курс: Введение в DS на УБ и МиРА (весна, 2022)
Преподаватель: Владимир Омелюсик

11 апреля

В предыдущих сериях

- Примеры задач теории вероятностей, статистики и машинного обучения.
- Генеральная совокупность и выборка.
- Типы переменных.
- Основные понятия ТВ.
- Функция распределения и функция вероятности.

Функция плотности
Некоторая функция $f(x)$, описывающая непрерывную случайную величину X, для которой верно:

$$F_X(a) = \mathbb{P}(X \leqslant a) = \int_{-\infty}^{a} f(x)dx$$

- Сами значения показывают «относительную вероятность», но обычно не интерпретируются.
- Площадь под ней равна 1.
- Самое важное свойство:

$$\mathbb{P}(a \leqslant X \leqslant b) = \int_{a}^{b} f(x)dx$$

Плотность как относительная вероятность

	Дискретная	Непрерывная
$\mathbb{P}\{X = a\}$	Ф. вероятности	0, но ф. плотности
$\mathbb{P}\{X \leqslant a\}$	Ф. распр.	Ф. распр.

Меры центральной тенденции

Математическое ожидание
Среднее (средневзвешенное по вероятностям) значение случайной величины.

$$\mathbb{E}(X) = \mathbb{P}(X = x_1)x_1 + \mathbb{P}(X = x_2)x_2 + \dots$$

$$\mathbb{E}(X) = \int_{-\infty}^{+\infty} xf(x)dx$$

Меры центральной тенденции

Квантиль (перцентиль)
Значение, которое случайная величина не превышает с фиксированной вероятностью (если вероятность в процентах, то называется перцентиль).

$$\begin{cases} \mathbb{P}(X \leqslant a_\alpha) \geqslant \alpha, \\ \mathbb{P}(X \geqslant a_\alpha) \geqslant 1 - \alpha. \end{cases}$$

Для непрерывных распределений: $F_X(a_\alpha) = \alpha$.

Медиана
Квантиль порядка 0.5.

Мода (неформально)
Наиболее вероятное значение случайной величины.

Пример с ростом собак

Меры разброса

Диспресия
Среднеквадратичное отклонение случайной величины относительно её математического ожидания.

$$\mathrm{Var}(X) = \mathbb{E}[(X - \mathbb{E}(X))^2] = \mathbb{E}(X^2) - \mathbb{E}(X)^2.$$

Стандартное отклонение
Корень из диспресии.

$$\sigma_X = \sqrt{\mathrm{Var}(X)}$$

Размах
Разность между наибольшим и наименьшим значением случайной величины.

Обобщающая картинка (Wikimedia Commons)

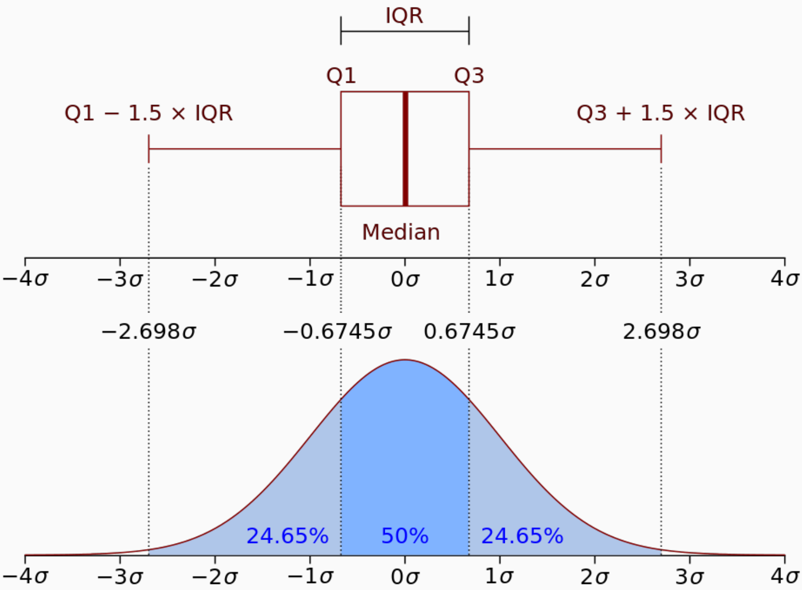

Два примера, которые спрашивают на собеседованиях

Многообразие оценок

«Хорошие» оценки

Пример: среднее число посетителей

- В магазин ежедневно приходят посетители. Требуется оценить некоторую величину, характеризующую среднее число посетителей за день.
- Для оценки будем записывать число посетителей в течение 100 дней:
$$X_1, X_2, X_3 \dots X_{100}.$$

Пример: среднее число посетителей (стандартное решение)

- Очевидный вариант – математическое ожидание.
- В качестве оценки математического ожидания рассчитаем среднее арифметическое по всем наблюдениям:

$$\hat{\mathbb{E}}(X) = \frac{X_1 + X_2 + \ldots X_{100}}{100}.$$

- Оценка математического ожидания равна среднему. Можно показать, что при некоторых условиях $\hat{\mathbb{E}}$ является «хорошей» оценкой $\mathbb{E}$.

Пример: среднее число посетителей (нестандартное решение)

- А что если $X_1, \ldots, X_{97}$ все меньше 3, а $X_{98}, \ldots, X_{100}$ все больше 40 (дни распродаж)?
- В качестве оценки средней величины разумнее взять медиану.

Обобщение: векторы

Ковариация и выборочная ковариация

$$\mathrm{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y)] = \mathbb{E}(XY) - \mathbb{E}(X)\,\mathbb{E}(Y)$$

$$\mathrm{sCov} = \frac{1}{N-1}\sum_{i=1}^{N}(X_i - \bar{X})(Y_i = \bar{Y})$$

Корреляция и выборочная корреляция

$$\mathrm{Corr}(X, Y) = \frac{\mathrm{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

$$\mathrm{scorr} = \frac{\mathrm{sCov}}{\mathrm{std}_X \mathrm{std}_Y}$$

Примеры: доходы регионов и цвет

Ковариация / корреляция и типы данных

Пример: задача из экзамена

Корреляция и причинность